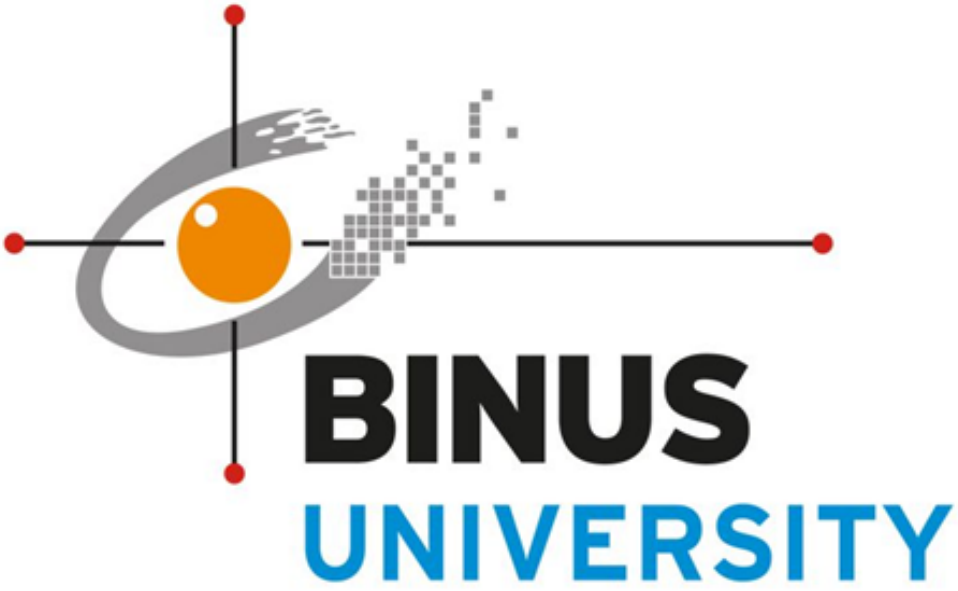
AIR VISION

AIR QUALITY INDEX USING MACHINE LEARNING



Nama Kelompok

1.Sabrian Zuhair 2802508110

2.Arief Ong 2802507612

3.Kenneth Howen 2802504346

I. Latar Belakang

Dibalik dinamika kota metropolitan seperti Jakarta, terdapat tantangan serius yang mengintai kesehatan jutaan warganya, yaitu polusi udara. Sebagai pusat aktivitas ekonomi dan industri, Jakarta tidak pernah 'istirahat' dari pergerakan kendaraan bermotor, operasional pabrik, hingga aktivitas domestik rumah tangga. Setiap hari kita disuguhi 'menu' polusi dari jutaan knalpot kendaraan yang menyemburkan gas CO, NO2, dan debu-debu halus (PM). Belum lagi ditambah asap industri yang nyumbang racun seperti Sulfur Dioksida (SO2). Intinya, udara yang kita hirup setiap hari sudah tercampur macam-macam zat kimia yang diam-diam bahaya sangat bagi kesehatan.

Akumulasi dari zat-zat ini menciptakan kabut polusi yang kini menjadi pemandangan sehari-hari, namun bahayanya sering kali diabaikan.Indikator yang paling mengkhawatirkan terlihat pada data Air Quality Index (AQI) yang kerap menunjukkan bahwa konsentrasi partikel PM2,5 dan PM10 di Jakarta telah melampaui ambang batas aman yang ditetapkan oleh World Health Organization (WHO). Partikel-partikel mikroskopis ini bukan sekadar debu biasa, ukurannya yang sangat kecil memungkinkan mereka lolos dari filter alami tubuh dan menyusup jauh ke dalam paru-paru, bahkan menembus aliran darah. Paparan jangka panjang terhadap partikel ini secara sistematis melemahkan pertahanan saluran pernapasan, menjadikan tubuh manusia jauh lebih rentan terhadap infeksi. Dampak nyata dari penurunan kualitas udara ini tercermin pada tingginya angka kejadian Infeksi Saluran Pernapasan Akut (ISPA).

ISPA kini adalah salah satu alasan utama tingginya kunjungan masyarakat ke fasilitas kesehatan di kota-kota besar. Udara yang terkontaminasi bertindak sebagai iritan kronis yang merusak jaringan mukosa saluran napas, memicu peradangan, dan mempermudah virus atau bakteri berkembang biak. Sayangnya, meskipun ancaman kesehatan ini sangat nyata, kesadaran dan kewaspadaan masyarakat masih relatif rendah.Masalah utamanya bukan hanya pada polusi itu sendiri, melainkan ketidaktahuan masyarakat mengenai kondisi udara yang mereka hirup setiap harinya. Banyak warga yang tetap beraktivitas di luar ruangan tanpa masker, bahkan saat kualitas udara sedang dalam level "Tidak Sehat" atau "Berbahaya". Hal ini terjadi karena kurangnya akses terhadap informasi yang real-time dan mudah dipahami. Data kualitas udara sering kali hanya tersedia sebagai angka statistik yang sulit diterjemahkan menjadi tindakan nyata oleh orang awam. Akibatnya, upaya pencegahan menjadi lambat dan sering kali terlambat sehingga masyarakat baru menyadari bahaya setelah jatuh sakit.

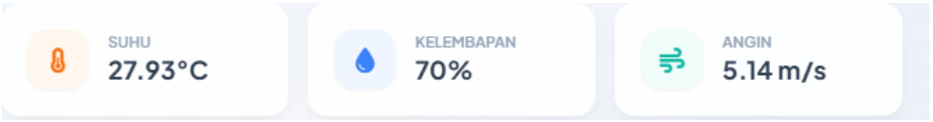
Oleh karena itu, diperlukan sebuah jembatan solusi berupa sistem prediksi kualitas udara yang cerdas dan komunikatif. Sistem ini tidak hanya berfungsi sebagai pemantau, tetapi juga sebagai peringatan dini (early-warning system) yang mampu memberikan informasi cepat dan akurat kepada publik. Dengan prediksi yang andal, masyarakat dapat mengubah perilaku mereka menjadi lebih preventif seperti memutuskan untuk mengurangi aktivitas di luar ruangan, menggunakan masker yang sesuai, atau melindungi kelompok rentan seperti anak-anak dan lansia sebelum paparan terjadi. Kehadiran teknologi ini diharapkan mampu menekan angka kejadian ISPA secara signifikan dan pada akhirnya, meningkatkan kualitas hidup masyarakat kota yang hidup berdampingan dengan tantangan polusi.

II. Fitur yang Tersedia

1. Pengambilan data cuaca secara real time

   Sumber : Data cuaca diperoleh dari OpenWeather API yang diakses dengan real time melalui koneksi internet menggunakan metode HTTP request. API ini memungkinkan sistem untuk memperoleh data cuaca berdasarkan lokasi kota tertentu.

   - Data yang diambil :
     - Temperature (Suhu)
       - Menunjukkan tingkat panas atau dinginnya udara di suatu kota dengan menggunakan satuan Celcius (°C)
     - Humidity (Kelembaban Udara)
       - Menunjukkan persentase kandungan uap air di udara, yang berpengaruh terhadap yang mempengaruhi kondisi lingkungan sekitar (%)
     - Wind Speed (Kecepatan angin)
       - Menunjukkan kecepatan pergerakan angin di suatu wilayah dengan satuan meter per detik (m/s)



Gambar 2.1 Tampilan suhu, kelembapan, dan kecepatan angin

Cara Kerja :

- Backend Flask memanggil OpenWeather API berdasarkan:
  - Latitude dan longitude kota
    - Parameter ini digunakan untuk menentukan lokasi kota atau wilayah yang diinginkan secara akurat.
- Data cuaca digunakan sebagai:
  - Input model AI
    - Data suhu, kelembaban, dan kecepatan angin dimanfaatkan sebagai variabel input pada model machine learning untuk melakukan analisis, prediksi, atau pengambilan keputusan tertentu sesuai dengan tujuan sistem.
  - Informasi tambahan untuk user
    - Data cuaca ditampilkan kepada user secara real-time sehingga user dapat mengetahui kondisi terkini lingkungan kota yang dipilih.

Sumber : Data Air Quality Index yang diperoleh dari AQICN (world Air Quality Index) yang ditampilkan secara real time

Data yang diambil :

- AQI
    - Merupakan indeks yang menunjukkan tingkat kualitas udara secara keseluruhan. Nilai AQI digunakan untuk mengklasifikasikan kondisi udara, mulai dari baik hingga berbahaya bagi kesehatan.
- PM 2.5
    - Partikel udara berukuran ≤ 2.5 mikrometer, merupakan indeks yang menunjukkan tingkat kualitas udara secara keseluruhan. Nilai AQI digunakan untuk mengklasifikasikan kondisi udara, mulai dari baik hingga berbahaya bagi kesehatan.
- PM10
    - Partikel udara berukuran ≤ 10 mikrometer yang juga dapat berdampak pada sistem pernapasan, meskipun ukurannya lebih besar dibanding PM2.5.



Gambar 2.2 Tampilan UI, analisis perbandingan, dan AQI

2. Kategori AQI

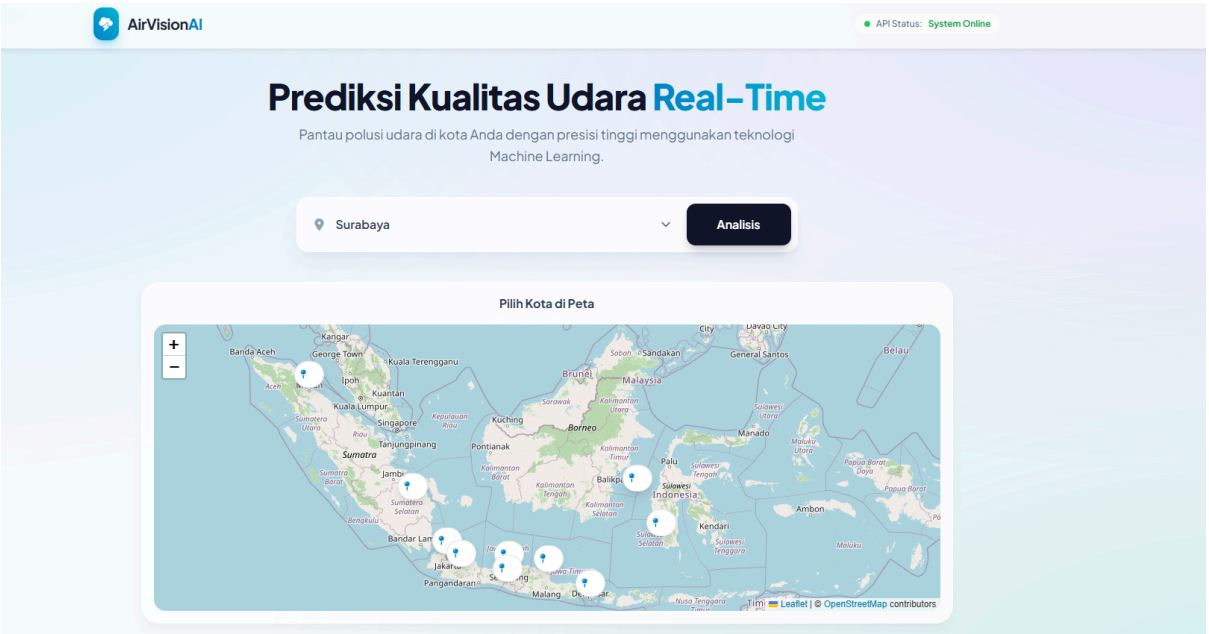
Dalam project ini kita bisa melihat kategori tiap AQI

AQI	Kategori
0-50	Good
51-100	Moderate
101-150	Unhealthy for sensitive group
151-200	Unhealthy
201-300	Very Unhealthy
300+	Hazardous



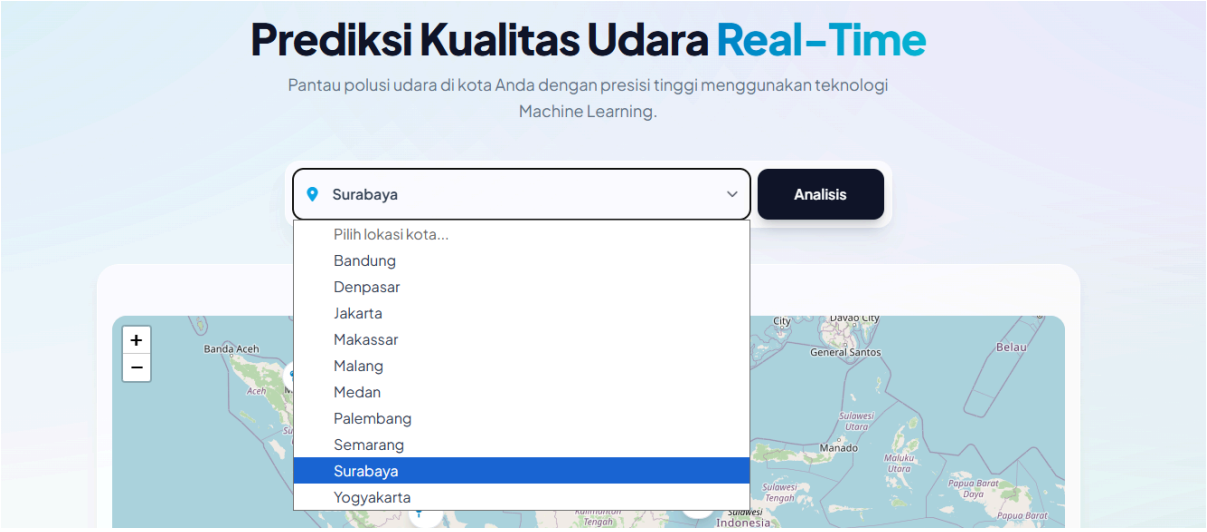
Gambar 2.3 Tampilan AQI

3. Penjelasan Secara Keseluruhan



Gambar 2.4 Homepage UI

Di UI Frontend kami terdapat visualisasi map, kita bisa memilih kota mana yang ingin kita lihat keterangan AQI, wind speed, temperatur dan kelembaban, selain itu terdapat kolom pilih kota yang dimana kita bisa memilih kota tanpa map.



Gambar 2.5 Pilihan kota untuk di analisis

Setelah memilih lokasi yang ingin kita lihat, kita mengklik tombol analis untuk melihat keterangan AQI Real Time, wind speed ,temperatur, dan kelembapan.



Gambar 2.6 Tampilah hasil analisis

Disini kita bisa melihat perbandingan langsung dari AQI aktual, Prediksi Random Forest dan Prediksi Linear Regression

III. Machine Learning yang Digunakan

a. Algoritma yang Digunakan

Untuk di primary kita akan menggunakan algoritma random forest tree, tetapi kita juga menggunakan linear regression untuk perbandingan.

b. Alasan

Alasan kenapa kita menggunakan random forest tree adalah karena mampu memberikan akurasi tinggi dan stabil pada data lingkungan yang bersifat kompleks dan tidak linear, seperti kualitas udara dan faktor faktor penentu AQI seperti suhu , kelembapan , kecepatan angin dan polutan, yang sering memiliki hubungan yang tidak sederhana dan random forest dapat menangkap pola tersebut dengan lebih baik dibandingkan linear regression.

Selain itu random forest bersifat robust terhadap noise overtitting. Dengan menggabungkan banyak decision tree melalui mekanisme ensemble, kesalahan dari satu pohon dapat dikoreksi oleh pohon lain sehingga model lebih andal saat digunakan pada data dunia nyata yang fluktuatif seperti data cuaca dan polusi.

Random forest juga memiliki keunggulan dalam mengolah data tanpa banyak asumsi awal, tidak memerlukan normalisasi ketat serta mampu menangani fitur dalam jumlah banyak. Hal ini membuatnya sangat cocok untuk sistem prediksi berbasis data real time, seperti aplikasi pemantauan kualitas udara.

Alasan tidak menggunakan linear regression karena hanya mampu memodelkan hubungan linear, sementar afaktor penentu AQI bersifat kompleks dan tidak linear. Model ini juga sensitif terhadap noise dan cenderung mengalami unrefitting sehingga kurang akurat untuk prediksi kualitas udara.

c. Persamaan Matematis

Random Tree Forest

$$AQI = \frac{1}{T}\sum_{t=1}^{T} f_t(x)$$

- T = jumlah pohon
- ft(x) = prediksi pohon ke t untuk input ke x

Contoh :

Kita memiliki data training

pm2.5	wind_speed	AQI
15	3.0	38
16	2.5	41
18	3.2	42
14	2.8	39

17	3.1	40

Data training ini kita masukkan untuk tree 1 yang dimana memiliki aturan pm2.5 <= 20 and wind_speed >= 2 ,

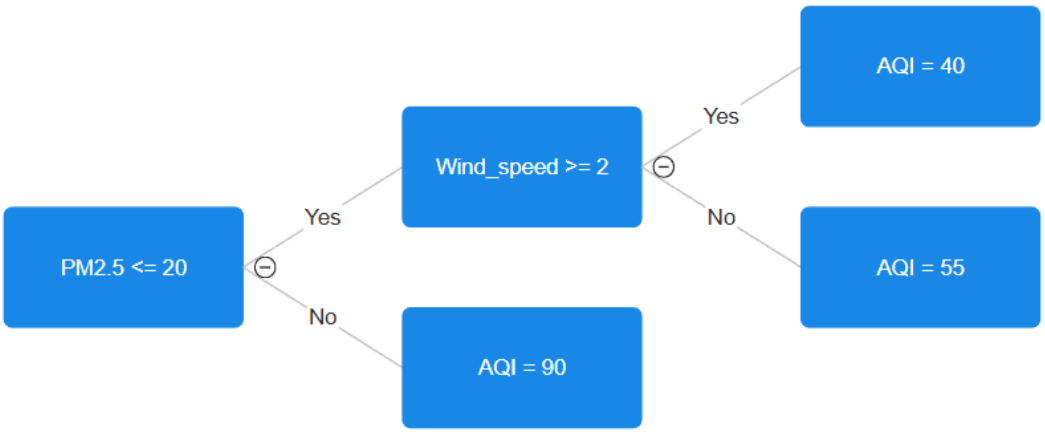
Jadi nilai leafnya itu adalah =

$$AQI\ LEAF = \frac{38 + 41 + 42 + 39 + 40}{5}$$

40

Lalu kita gunakan algoritma Random Tree Forest yang dasarnya random tree forest memiliki aturan condition if else

Contoh untuk tree 1



Gambar 3.1 Tree 1

Maka untuk AQI tree 1 adalah 40

Lalu pohon berfikir seperti

- Jika PM2.5 tinggi → udara buruk
- Jika PM2.5 rendah dan angin kencang maka udara lebih baik
- Jika kelembaban tinggi udara cenderung tidak sehat

Hasil untuk tree 1 adalah 40 dan seterusnya

Contoh implementasi persamaan matematis

Pohon	Cara berfikir	Prediksi AQI
Tree 1	Fokus PM2.5	40
Tree 2	Fokus suhu dan angin	35
Tree 3	Fokus kota dan PM10	45
Tree 4	Fokus Kelembapan	38
Tree 5	Kombninasi acak	42

Cara random forrest mengambil keputusan adalah

$$AQI = \frac{40 + 35 + 45 + 38 + 42}{5} = 40$$

Maka AQI prediksi adalah 40

Linear Regression

$$AQI = \beta 0 + \beta 1\,(Temperature) + \beta 2\,(Humidity) + \beta 3\,(Wind\ Speed) + \beta 4(PM2.5) + \beta 5(PM10) + \in$$

- (Beta 0): konstanta (intercept)
- (Beta 1): suhu udara
- (Beta 2): kelembapan
- (Beta 3): kecepatan angin
- (PM2.5, PM10): kadar partikel dalam udara

d. Tools yang digunakan

- Bahasa yang digunakan :

  - Backend : Python

  Python di dalam project ini digunakan untuk :

  - Training model Machine Learning
  - Data preprocessing

- Pembuatan Flask API
- Penghubung Backend dengan Frontend

- Frontend : HTML

- Library yang digunakan untuk Machine Learning

  - Scikit-learn

  Digunakan untuk :

  - Membuat model Machine Learning
  - Melakukan train test split
  - Melakukan evaluasi model

  Contoh implementasi dalam code :

```
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score, confusion_matrix, classification_report
from sklearn.model_selection import train_test_split, KFold, cross_val_score
from sklearn.pipeline import Pipeline
```

  - Pandas

  Digunakan untuk :

  - Membaca dataset (CSV)
  - Mengubah data ke DataFrame
  - Membersihkan data yang lama

  Contoh implementasi dalam code :

```
import pandas as pd
```

  - Numpy

  Digunakan untuk :

  - Operasi Numerik
  - Konversi data ke array untuk model ML

- Library Backend

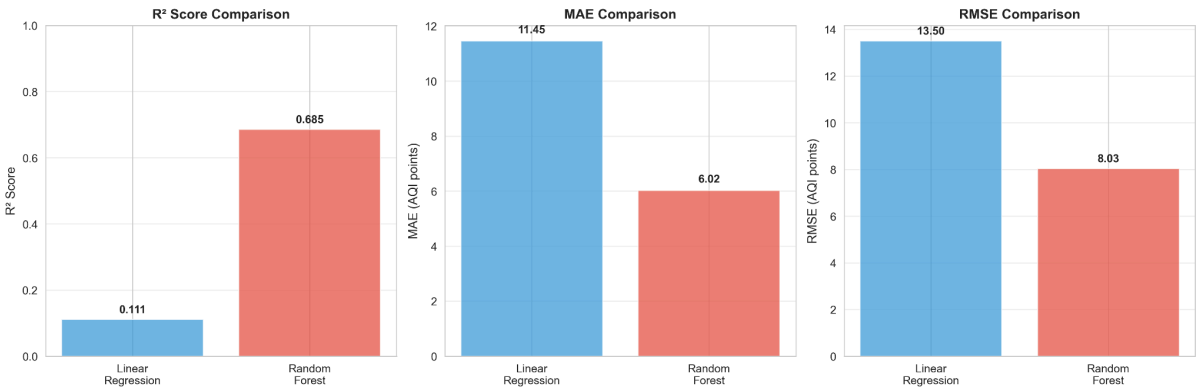
  - Flask

  Framework backend untuk membuat API

Contoh :

```
from flask import Flask, jsonify
from flask_cors import CORS
import requests
```

IV. Hasil Test Project



Gambar 4.1 Hasil R^2 , MAE, dan RMSE

- Deskripsi pada gambar
  - R^2 Score : Akurasi Model
  - MAE (mean Absolute Error) : rata rata kesalahan prediksi
  - RMSE (Root Mean Squared Error) : kesalahan besar dalam model
- Perbandingan R^2

Model	R^2 Score
Linear Regression	0.111
Random Forest	0.685

Penjelasan :

- Linear Regression dengan ($R^2 = 0.111$) :
  - Nilai R^2 yang sangat rendah menunjukkan bahwa model Linear Regression hanya mampu menjelaskan sekitar 11,1% variasi AQI. Hal ini mengindikasikan bahwa hubungan antara AQI dengan fitur-fitur input seperti suhu, kelembaban, kecepatan angin, serta parameter kualitas udara lainnya tidak bersifat linear. Dengan kata lain, asumsi hubungan linear yang digunakan oleh Linear Regression tidak mampu merepresentasikan pola data yang sebenarnya, sehingga performa model menjadi kurang akurat.
- Random Forest dengan ($R^2 = 0.685$) :

    - Nilai R^2 sebesar 0.685 menunjukkan bahwa model Random Forest mampu menjelaskan sekitar 68,5% variasi AQI. Hal ini menandakan bahwa Random Forest memiliki kemampuan yang jauh lebih baik dalam menangkap pola non-linear dan interaksi dari berbagai faktor yang banyak. Random Forest mampu mempelajari hubungan yang lebih kompleks dibandingkan model linear sederhana karena berbasis decision tree.

- Perbandingan MAE

Model	MAE
Linear Regression	11.45
Random Forest	6.02

Penjelasan :

- Linear Regression (MAE = 11.45)
    - Nilai MAE sebesar 11.45 menunjukkan bahwa secara rata-rata, prediksi model Linear Regression meleset sekitar ±11 satuan AQI dari nilai sebenarnya. Kesalahan ini tergolong cukup besar, terutama jika digunakan untuk pemantauan kualitas udara yang membutuhkan ketelitian.
- Random Forest (MAE = 6.02)
    - Nilai MAE yang lebih kecil menunjukkan bahwa prediksi Random Forest lebih mendekati nilai AQI yang sebenarnya, dengan rata-rata kesalahan sekitar ±6 satuan AQI. Hal ini menunjukkan peningkatan akurasi yang signifikan dibandingkan Linear Regression.

Contoh Jika AQI 40 :

- Linear Regression memprediksi 29 atau 50, yang cukup jauh dari nilai sebenarnya
- Random Forest lebih dekat dengan nilai asli yaitu 40, sehingga lebih akurat

- RMSE

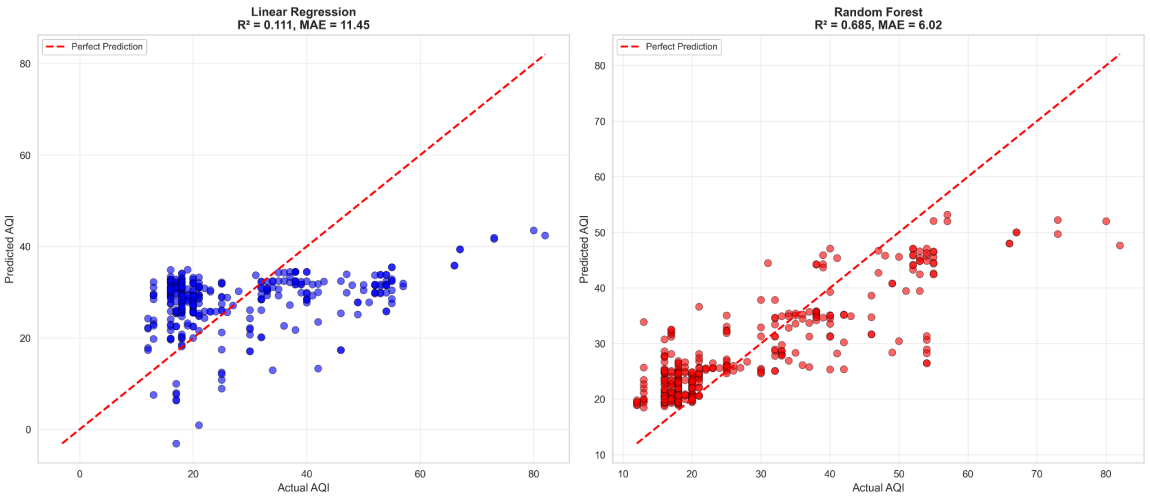
Model	RMSE
Linear Regression	13.50
Random Forest	8.03

Penjelasan :

- Linear Regression sering membuat kesalahan besar karena memiliki keterbatasan dalam memodelkan hubungan antara fitur input dan AQI karena asumsi linearitas yang tidak sesuai dengan karakteristik data cuaca yang tidak linear dan memiliki banyak faktor.
- Random Forest menunjukkan performa yang lebih unggul secara konsisten dan lebih stabil, baik dari sisi R^2, tingkat kesalahan rata-rata (MAE), maupun kestabilan prediksi (RMSE).

- Kesimpulan

Berdasarkan hasil evaluasi menggunakan R^2 Score, MAE dan RMSE, Random Forest menunjukkan performa yang jauh lebih baik dibandingkan Linear Regression. Hal ini disebabkan oleh kemampuan random forest dalam menangkap hubungan non-linear dan interaksi kompleks antara variabel lingkungan seperti cuaca,partikel polusi dan lokasi kota.



Gambar 4.2 Perbandingan hasil linear regression dengan random forest

- Penjelasan Gambar
    - Memiliki sumbu X: AQI aktual
    - Memiliki sumbu y: AQI prediksi model
    - Garis merah: Perfect Prediction
    - Semakin dekat dengan titik merah maka semakin akurat modelnya
- Linear Regression
    - Titik titik menyebar jauh dari garis merah
    - Banyak prediksi menumpuk di kisaran AQI 25-35
    - Untuk AQI akutal tinggi seperti 50-80 model gagal mengikuti
    - Terjadi underfitting karena model terlalu sederhana
    - Model tidak representatif untuk data AQI dan memberikan prediksi yang kurang akurat serta bias ke nilai tengah
- Random Forest
    - Titik titik jauh lebih dekat ke garis merah
    - Pola diagonal terbentuk dengan jelas
    - Model mampu mengikuti
    - Model mampu mempelajari pola data AQI dengan baik dan menghasilkan prediksi yang jauh lebih akurat.
- Kesimpulan

    Berdasarkan visualisasi scatter plot antara nilai aktual dan nilai prediksi random forest menunjukkan performa yang jauh lebih baik dibandingkan linear regression.Hal ini ditandai dengan titik titik prediksi yang lebih mendekati garis perfect prediction, nilai R^2 yang lebih tinggi serta MAE yang lebih rendah. Sebaliknya Linear Regression mengalami underfitting dan tidak mampu mengikuti pola non linear pada data AQI.

Metric	Linear Regression	Random Forest
R^2 Score	0.1048	0.7066
MAE	11.50	5.92
RMSE	13.49	7.72

OVERFITTING ANALYSIS:

Linear Regression:

Train R^2: 0.1567, Test R^2: -0.1902, Gap: 0.3469

SIGNIFICANT OVERFITTING detected (gap > 0.2)

Random Forest:

Train R^2: 0.7028, Test R^2: 0.7078, Gap: -0.0050

Good generalization (gap $\leq$ 0.1)

V. Pembagian Tugas Tim

Nama	Tugas
Sabrian Zuhair (2802508110)	● Pengerjaan testing AI ○ Code Generate Dataset ○ Code untuk testing ai ■ Code testing ai untuk Random Forrest Algorithm ■ Code testing ai untuk Linear Regression ■ Code testing AI Comparison ● Pengerjaan Backend API ○ Pengerjaan API agar connect Backend dengan Frontend ● Evaluasi hasil testing ● Pembuatan Laporan ○ Pengerjaan Hasil test project ○ Penjelasan hasil test AI ■ Penjelasan Gambar Pada Hasil Testing ■ Penjelasan Gambar Pada Fitur ○ Penjelasan model yang digunakan ○ Penjelasan Code di dalam file ● Menentukan Model Machine Learning ● Pengerjaan UI UX design ● Pembuatan PPT ○ Hasil Test ○ Demo Aplikasi ○ Penjelasan code
Arief Ong	● Pengerjaan Frontend Code (50%) ● Pembuatan Laporan ○ Pengerjaan Fitur yang tersedia ○ Pengerjaan Latar Belakang ○ Pengerjaan Penjelasan Machine Learning yang digunakan ○ Persamaan Matematika ● Evaluasi hasil testing ● Pembuatan PPT ○ Latar Belakang

	○ Manfaat ○ Fitur ● Pencarian Data Air Quality di kota-kota Indonesia (AQICN) mencakup 10 kota besar. ● Pencarian Data untuk data suhu, wind speed dan kelembaban di OpenWeather untuk 10 kota besar di indonesia. ● Menentukan Model Machine Learning
Kenneth Howen	● Pengerjaan Frontend Code (50%) ● Pembuatan Laporan ○ Pengerjaan Fitur yang Tersedia ○ Penjelasan Gambar ■ Fitur ■ Tampilan ■ Hasil Testing Project ○ Persamaan Matematika ○ Hasil Test Project ● Pembuatan PPT ○ Model Machine Learning ○ Persamaan Matematika ● Pencarian Data Air Quality di kota-kota Indonesia (AQICN & OpenWeather API) ● Menentukan Model Machine Learning ● Evaluasi hasil testing

VI. Source Code

- Penjelasan untuk code berada pada comment line code dan video AIR QUALITY INDEX USING MACHINE LEARNING https://drive.google.com/drive/folders/18yxUfbYSZ0Bjli7BCVfaicYCkFc5M3gS?usp=drive_link